Rede Neural Convolucional

August 6, 2019

1 Rede Neural Convolucional para Reconhecimento de Imagens de Cães e Gatos

Nesse documento mostraremos como construir uma rede neural convolucional para reconhecimento de imagens de cães e gatos, para isso utilizaremos a biblioteca Keras com o TensorFlow como backend para facilitar a nossa implementação. Essas são bibliotecas muito populares na área de inteligência artificial e disponibilizam diversas ferramentas que agilizam no desenvolvimento do projeto.

1.1 O que é uma Rede Neural Convolucional?

Uma rede neural convolucional (CNN do inglês Convolutional Neural network ou ConvNet) é uma classe de rede neural artificial do tipo feed-forward, que pode captar uma imagem de entrada, atribuir importância (pesos e vieses que podem ser aprendidos) a vários aspectos/objetos da imagem e ser capaz de diferenciar um do outro; vem sendo aplicada com sucesso no processamento e análise de imagens digitais.

O pré-processamento exigido em uma ConvNet é muito menor em comparação com outros algoritmos de classificação. Enquanto nos métodos primitivos os filtros são feitos à mão, com treinamento suficiente, as ConvNets têm a capacidade de aprender esses filtros/características. Ela usa uma variação de perceptrons multicamada desenvolvidos de modo a demandar o mínimo pré-processamento possível. A arquitetura de uma ConvNet é análoga àquela do padrão de conectividade de neurônios no cérebro humano e foi inspirada na organização do Visual Córtex.

Os neurônios individuais respondem a estímulos apenas em uma região restrita do campo visual conhecida como Campo Receptivo. Uma coleção desses campos se sobrepõe para cobrir toda a área visual. Uma ConvNet é capaz de capturar com sucesso as dependências espaciais e temporais em uma imagem através da aplicação de filtros relevantes. A arquitetura executa um melhor ajuste ao conjunto de dados da imagem devido à redução no número de parâmetros envolvidos e à capacidade de reutilização dos pesos. Em outras palavras, a rede pode ser treinada para entender melhor a sofisticação da imagem.

A função da ConvNet é reduzir as imagens para uma forma mais fácil de processar, sem perder recursos que são críticos para obter uma boa previsão. Isso é importante quando queremos projetar uma arquitetura que não seja apenas boa em recursos de aprendizado, mas que também seja escalável para conjuntos de dados massivos.

Essas redes usam uma arquitetura especial que é particularmente bem adaptada para classificar imagens. O uso dessa arquitetura torna as redes convolucionais rápidas de treinar. Isso, por sua vez, nos ajuda a treinar redes profundas de muitas camadas, que são muito boas na classificação de imagens. Hoje, redes neurais convolucionais ou alguma variante próxima são usadas na

maioria das redes neurais para reconhecimento de imagem. É usada principalmente em reconhecimento de imagens e processamento de vídeo, embora já tenha sido aplicada com sucesso em experimentos envolvendo processamento de voz e linguagem natural.

1.2 Principais etapas

Na camada convolucional cada neurônio é um filtro aplicado a uma imagem de entrada e cada filtro é uma matriz de pesos. Cada filtro (neurônio) dessa camada irá processar a imagem e produzir uma transformação dessa imagem por meio de uma combinação linear dos pixels vizinhos.

Cada região da imagem processada pelo filtro é chamada de campo receptivo local (local receptive field); um valor de saída (pixel) é uma combinação dos pixels de entrada nesse campo receptivo local. No entanto todos os campos receptivos são filtrados com os mesmos pesos locais para todo pixel. Isso é o que torna a camada convolucional diferente da camada FC. Assim, um valor de saída ainda terá o formato bidimensional. Chamamos de mapa de características a saída de cada neurônio da camada convolucional. Os mapas gerados pelos diversos filtros da camada convolucional são empilhados, formando um tensor cuja profundidade é igual ao número de filtros. Esse tensor será oferecido como entrada para a próxima camada.

Outro aspecto importante para se mencionar é o passo ou stride. A convolução convencional é feita com passo/stride 1, ou seja, filtramos todos os pixels e portanto para uma imagem de entrada de tamanho 64 Œ 64, geramos uma nova imagem de tamanho 64 Œ 64. O uso de strides maiores que 1 é comum quando deseja-se reduzir o tempo de execução, pulando pixels e assim gerando imagens menores. Ex. com stride = 2 teremos como saída uma imagem de tamanho 32Œ32.

É comum reduzir a dimensão espacial dos mapas ao longo das camadas da rede. Essa redução em tamanho é chamada de pooling sendo a operação de máximo maxpooling comumente empregada. Essa operação tem dois propósitos: em primeiro lugar, o custo computacional, pois como a profundidade dos tensores, d, costuma aumentar ao longo das camadas, é conveniente reduzir a dimensão espacial dos mesmos. Em segundo, reduzindo o tamanho das imagens obtemos um tipo de composição de banco de filtros multiresolução que processa imagens em diferentes espaços escala. Há estudos a favor de não utilizar pooling, mas aumentar o stride nas convoluções, o que produz o mesmo efeito redutor.

Camadas FC são camadas presentes em redes neurais MLP. Nesse tipo de camada cada neurônio possui um peso associado a cada elemento do vetor de entrada. Em CNNs utiliza-se camadas FC posicionadas após múltiplas camadas convolucionais. A transição entre uma camada convolucional (que produz um tensor) e uma camada FC, exige que o tensor seja vetorizado.

CNNs tradicionais são combinação de blocos de camadas convolucionais (Conv) seguidas por funções de ativação, eventualmente utilizando também pooling (Pool) e então uma séria de camadas completamente conectadas (FC), também acompanhadas por funções de ativação.

Com uma função de custo definida, precisa-se então ajustar os parâmetros de forma que o custo seja reduzido. Para isso, em geral, usa-se o algoritmo do Gradiente Descendente em combinação com o método de backpropagation, que permite obter o gradiente para a sequência de parâmetros presentes na rede usando a regra da cadeia.

Uma forma de acelerar o treinamento é utilizando métodos que oferecem aproximações do Grandiente Descendente, por exemplo usando amostras aleatórias dos dados ao invés de analisando todas as instâncias existentes. Por esse motivo, o nome desse método é Gradiente Descendente Estocástico, já que ao invés de analisar todos dados disponíveis, analisa-se apenas uma amostra, e dessa forma, adicionando aleatoriedade ao processo. Também é possível calcular o Gradiente Descende usando apenas uma instância por vez (método mais utilizado para analisar fluxos de dados ou aprendizagem online).

A inicialização dos parâmetros é importante para permitir a convergência da rede. Atualmente, se utiliza números aleatórios sorteados a partir de uma distribuição Gaussiana N (,) para inicializar os pesos. Pode-se utilizar um valor fixo como o = 0.01. Porém o uso desse valor fixo pode atrapalhar a convergência. Como alternativa, recomenda-se usar = 0, = p 2/nl , onde nl é o número de conexões na camada l, e inicializar vetores bias com valores constantes.

Pre-processamento – é possível pré-processar as imagens de entrada de diversas formas. As mais comuns incluem: (i) computar a imagem média para todo o conjunto de treinamento e subtrair essa média de cada imagem; (ii) normalização z-score, (iii) PCA whitening que primeiramente tenta descorrelacionar os dados projetando os dados originais centrados na origem em uma auto-base (em termos dos auto-vetores), e então dividindo os dados nessa nova base pelos auto-valores relacionados de maneira a normalizar a escala. O método z-score é o mais utilizado dentre os citados (centralização por meio da subtração da média, e normalização por meio da divisão pelo desvio padrão), o que pode ser visto como uma forma de realizar whitening.

O processo de fine-tuning consiste basicamente de continuar o treinamento a partir dos pesos iniciais, mas agora utilizando um subconjunto de sua base de dados. Note que é provável que essa nova base de dados tenha outras classes (em contrapartida por exemplo às 1000 classes da ImageNet). Assim se você deseja criar um novo classificador será preciso remover a última camada e adicionar uma nova camada de saída com o número de classes desejado, a qual deverá ser treinada do zero a partir de uma inicialização aleatória.

Para obter extração de características, mesmo sem realizar fine-tuning, oferecese como entrada as imagens desejadas, e utilizamos como vetor de características a saída de uma das camadas da rede (antes da camada de saída). Comumente se utiliza a penúltima camada: por exemplo na VGGNet a FC2 tem 4096 neurônios, gerando um vetor de 4096 elementos, já na Inception V3 temos 2048 elementos na penúltima camada. Caso a dimensionalidade seja alta, é possível utilizar algum método de redução de dimensionalidade ou quantização baseada por exemplo em PCA ou Product Quantization.

1.3 Metodologia

Nós utilizaremos nesse projeto as ferramentas que o Anaconda nos oferece, juntamente com a IDE Spyder. Primeiramente algumas bibliotecas precisam ser instaladas:

- keras
- tensorFlow
- numpy

1.3.1 Construção da rede neural

Após instaladas, começaremos nosso código importando algumas ferramentas dessas bibliotecas:

```
In [1]: from keras.models import Sequential
        from keras.layers import Conv2D
        from keras.layers import MaxPooling2D
        from keras.layers import Flatten
        from keras.layers import Dense

Using TensorFlow backend.
```

Importado nossas bibliotecas, inicializaremos nossa rede:

```
In [6]: rede_neural = Sequential()
```

Agora adicionaremos a primeira camada convolucional da nossa rede e definiremos os parâmetros para o formato dos dados de entrada e a função de ativação. Usaremos 64 features para um array 2D e definiremos o nosso array com o formato de 3x3.

Todas a imagens de entrada de 64x64 pixels serão convertidas em um array 3D, pois as imagens coloridas RGB possuem 3 canais de cores.

```
In [7]: rede_neural.add(Conv2D(64, (3, 3), input_shape = (64, 64, 3), activation = 'relu'))
```

Logo depois da primeira camada, adicionaremos um agrupamento (pooling) para reduzir o tamanho do mapa de features obtida e descartar informações que não são tão relevantes.

Nesse caso utilizaremos o MaPooling que reduzirá pela metade o mapa e deixará somente o pontos característicos mais relevantes.

```
In [8]: rede_neural.add(MaxPooling2D(pool_size = (2, 2)))
```

Feito isso, adicionaremos uma segunda camada convolucional para tornar nossa rede mais profunda juntamente com outra de pooling. Porém dessa vez adicionaremos somente 32 features na camada convolucional.

```
In [9]: rede_neural.add(Conv2D(32, (3, 3), activation = 'relu'))
        rede_neural.add(MaxPooling2D(pool_size = (2, 2)))
```

Ao fim de nossas camadas convolucionais, aplicaremos um Flatten para converter os dados que estão em uma estrutura 2D para uma estrutura 1D.

```
In [10]: rede_neural.add(Flatten())
```

Nosso próximo passo é conectar todas as camadas. Utilizaremos a função de ativação ReLu em uma camada e a função de ativação Sigmóide na camada de saída para obter as probabilidades da imagem ser de gato ou de cachorro.

Dificilmente um modelo terá 100% de acertos, pois ele apenas calcula uma probabilidade.

```
In [11]: rede_neural.add(Dense(units = 128, activation = 'relu'))
         rede_neural.add(Dense(units = 1, activation = 'sigmoid'))
```

Finalmente após construirmos todas as camadas da nossa rede neural, iremos compilar ela. Utilizaremos o otimizador "Adam" e uma função loss "entropia binária cruzada" como parâmetros para esse processo. E por fim a nossa métrica será a acurácia, pois ela é nossa principal preocupação.

```
In [13]: rede_neural.compile(optimizer = 'adam', loss = 'binary_crossentropy', metrics = ['accur
```

1.3.2 Treinamento

Pré-Processamento Antes de começarmos a treinar nossa rede, precisamos primeiro pré-processar nossas imagens. Essa etapa é uma etapa crucial para o funcionamento do nosso projeto pois ele serve para normalizar os dados que servirão de entrada para a nossa rede.

Para isso utilizaremos a função ImageDataGenerator() da biblioteca Keras para ajustar alguns parâmetros das imagens de treino e de validação.

```
In [14]: from keras.preprocessing.image import ImageDataGenerator

         train_datagen = ImageDataGenerator(rescale = 1./255,
                                            shear_range = 0.2,
                                            zoom_range = 0.2,
                                            horizontal_flip = True)

         test_datagen = ImageDataGenerator(rescale = 1./255)
```

Agora aplicaremos os objetos criados anteriormente para pré-processar nossas imagens de treino e de validação.

```
In [15]: training_set = train_datagen.flow_from_directory('dogs-and-cats-dataset/training_set',
                                                         target_size = (64, 64),
                                                         batch_size = 32,
                                                         class_mode = 'binary')

         test_set = test_datagen.flow_from_directory('dogs-and-cats-dataset/test_set',
                                                     target_size = (64, 64),
                                                     batch_size = 32,
                                                     class_mode = 'binary')
```

```
Found 8000 images belonging to 2 classes.
Found 2000 images belonging to 2 classes.
```

1.3.3 Treinamento da rede

Para treinar nossa rede, usamos 8000 passos em nosso conjunto de treinamento para cada época, e escolhemos 2000 etapas de validação para as imagens de validação. A quantidade de épocas foi definida para o valor de 7.

Esse processo de treinamento pode ser um pouco demorado dependendo da capacidade de cada computador.

Para um processo mais rápido ou para computadores com baixa capacidade de processamento, o valor de épocas pode ser reduzido para 5, mas isso afetará um pouco a acurácia da sua rede. Diminuir os dados de treinamento também pode ser uma opção.

```
In [ ]: rede_neural.fit_generator(training_set,
                                  steps_per_epoch = 8000,
                                  epochs = 7,
                                  validation_data = test_set,
                                  validation_steps = 2000)
```

Depois de ter treinado sua rede iremos salvá-lo em um arquivo .json. Seus pesos serão salvos em um arquivo .h5 para serem utilizados depois sem ser necessário treiná-lo de novo.

```
In [16]: rede_neural_json = rede_neural.to_json()
         with open("ARQUIVO.json","w") as json_file:
             json_file.write(rede_neural_json)

         rede_neural.save_weights("ARQUIVO.h5")
```

1.4 Resultados

Agora iremos testar o nosso modelo treinado, fazendo-o predizer imagens que ele nuca viu antes.

Primeiro carregaremos o nosso modelo e seus pesos salvos.

```
In [18]: from keras.models import model_from_json
         #Informe o diretório em que seu arquivo foi salvo
         json_file = open("ModeloConv2D_7e.json","r")
         modelo_json = json_file.read()
         json_file.close()

         modelo = model_from_json(modelo_json)
         modelo.load_weights("ModeloConv2D_7e.h5")
         modelo.compile(optimizer = 'adam', loss = 'binary_crossentropy', metrics = ['accuracy']
```

Vamos criar agora uma função para carregar a nossa imagem com as mesmas dimensões usadas nas imagens de treino e depois convertê-la para um array. Depois disso faremos nosso modelo prever se a imagem contém um gato ou um cachorro.

```
In [19]: import numpy as np
         from IPython.display import Image
         from keras.preprocessing import image
         #path é o camiho onde sua imagem está
         def read_image(path):
             test_image = image.load_img(path, target_size = (64,64))
             test_image = image.img_to_array(test_image)
             test_image = np.expand_dims(test_image, axis = 0)
             return test_image

In [20]: test_image = read_image("teste/1.jpg")

         result = modelo.predict(test_image)

         if result[0][0] == 1:
             prediction = 'Cachorro'
         else:
             prediction = 'Gato'

         print("Imagem reconhecida como: ", prediction)
         Image(filename='teste/1.jpg')
```

```
Imagem reconhecida como:  Gato
```

Out[20]:

Nossa primeira imagem de teste foi reconhecida com sucesso. Isso se deve ao fato de que nossa rede conseguiu aprender com base no que ele viu antes na fase de treinamento, padrões que consegue identificar se a imagem é de um gato ou cachorro.

Esse padrões são nada menos que pesos que representam uma determinada característica da imagem, como as patas ou as orelhas por exemplo.

In [21]:
```
test_image = read_image("teste/2.jpg")

result = modelo.predict(test_image)

if result[0][0] == 1:
    prediction = 'Cachorro'
else:
    prediction = 'Gato'

print("Imagem reconhecida como: ", prediction)
Image(filename='teste/2.jpg')
```

```
Imagem reconhecida como:  Cachorro
```

Out[21]:

A segunda imagem também conseguiu ser reconhecida com sucesso.

In [22]:
```
test_image = read_image("teste/3.jpg")

result = modelo.predict(test_image)

if result[0][0] == 1:
    prediction = 'Cachorro'
else:
    prediction = 'Gato'

print("Imagem reconhecida como: ", prediction)
Image(filename='teste/3.jpg')
```

```
Imagem reconhecida como:  Gato
```

Out[22]:

Nossa terceira imagem, mesmo com o gato estar usando um chapéu, a nossa rede neural conseguiu identificá-lo corretamente.

```
In [23]: test_image = read_image("teste/4.jpg")

         result = modelo.predict(test_image)

         if result[0][0] == 1:
             prediction = 'Cachorro'
         else:
             prediction = 'Gato'

         print("Imagem reconhecida como: ", prediction)
         Image(filename='teste/4.jpg')
```

```
Imagem reconhecida como:  Cachorro
```

```
Out[23]:
```

A quarta imagem também foi reconhecida com sucesso.

```
In [24]: test_image = read_image("teste/5.jpg")

         result = modelo.predict(test_image)

         if result[0][0] == 1:
             prediction = 'Cachorro'
         else:
             prediction = 'Gato'

         print("Imagem reconhecida como: ", prediction)
         Image(filename='teste/5.jpg')
```

```
Imagem reconhecida como:  Cachorro
```

```
Out[24]:
```

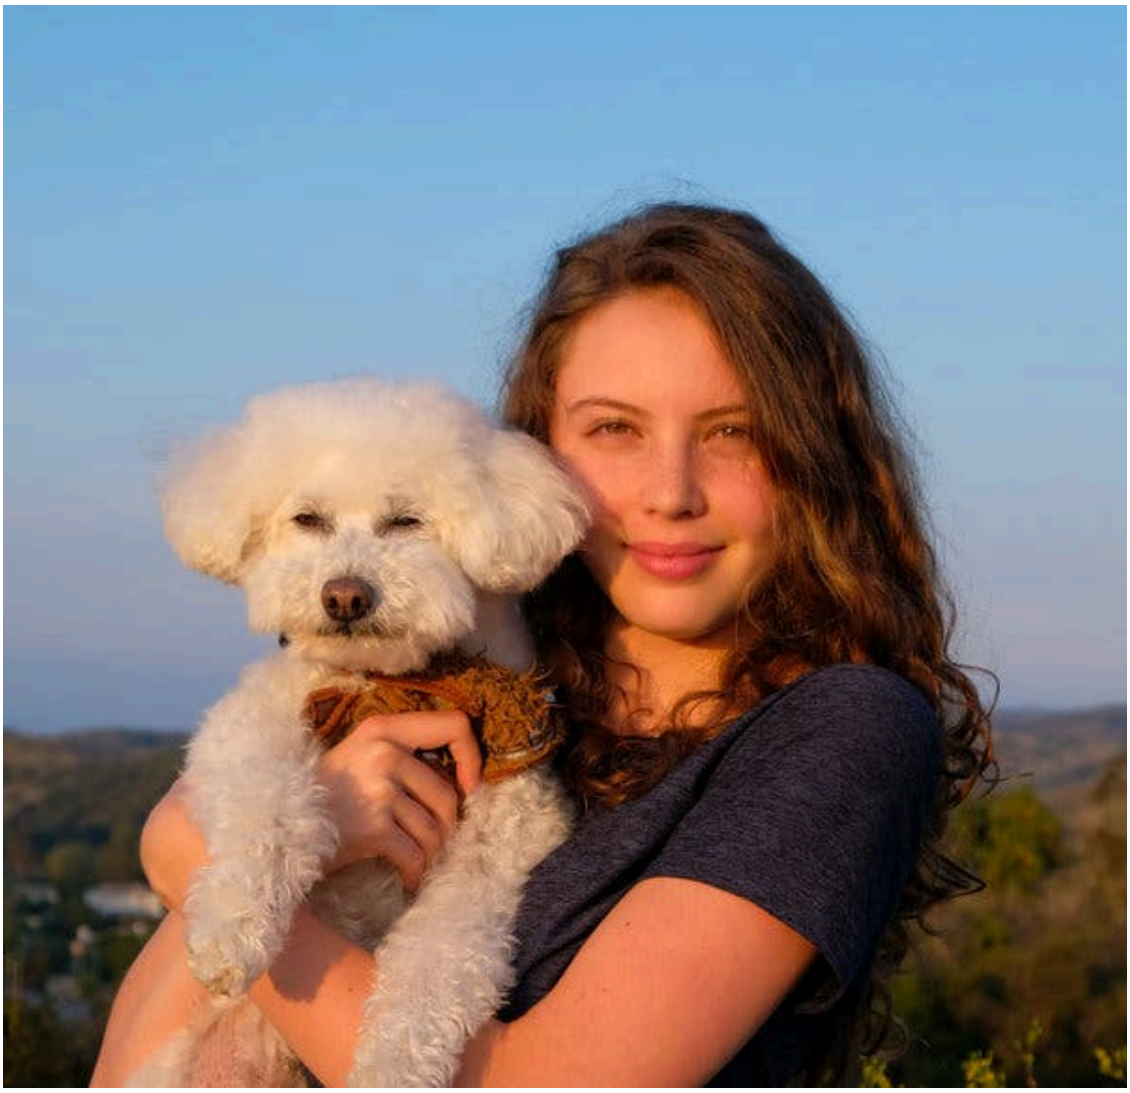

Nossa quinta imagem possui um cachorro ao lado de uma mulher, mesmo assim a nossa rede neural conseguiu identificá-lo corretamente.

```
In [25]: test_image = read_image("teste/6.jpg")

         result = modelo.predict(test_image)

         if result[0][0] == 1:
             prediction = 'Cachorro'
         else:
             prediction = 'Gato'

         print("Imagem reconhecida como: ", prediction)
         Image(filename='teste/6.jpg')
```

```
Imagem reconhecida como:  Cachorro
```

Out[25]:

Na sexta imagem a nossa rede neural não conseguiu identificá-lo corretamente, isso pode se dar por diversos fatores como o número de dados para treino não ter sido o suficiente, ou até mesmo a topologia escolhida para nossa rede neural não ter sido a mais adequada para esse problema. Porém isso não é algo para se desesperar, pois como foi falado anteriormente, dificilmente uma rede neural irá acertar tudo.

In [26]:
```
test_image = read_image("teste/7.jpg")

result = modelo.predict(test_image)

if result[0][0] == 1:
    prediction = 'Cachorro'
else:
    prediction = 'Gato'

print("Imagem reconhecida como: ", prediction)
Image(filename='teste/7.jpg')
```

```
Imagem reconhecida como:  Cachorro
```

Out[26]:

E para finalizar, nossa sétima imagem também não foi reconhecida corretamente.

1.5 Conclusão

O resultado final do nosso projeto foi de uma acurácia de aproximadamente 99% em nosso conjunto de treino e de 79% em nosso conjunto de testes.

Após isso, das nossas 7 imagens testadas, apenas 5 foram reconhecidas corretamente e 2 não. Algumas sugestões para serem testadas a fim de obter um resultado melhor, são:

- Aumentar a resolução das imagens, isso faz com que a nossa rede consiga reconhecer características mais precisamente.
- Aumentar o número de épocas para tornar o aprendizado mais profundo.

- Alterar a topologia da nossa rede adicionando mais uma camada convolucional, ou adicionando o número de neurônios.
- Alterar alguns parâmetros da rede.